สัปดาห์ที่ 2 · 07_Skill_Optimization

Skill Optimization

ทำให้สกิลเก่งขึ้นด้วยการวัด
ต่อยอดจาก base skills ของบท 05

วัด → หาสาเหตุ → แก้ → วัดซ้ำ → ประตูรับ · ตัวเลขทุกตัวมาจากการรันจริง

10 พ.ย. 2026 · **157 รอบ**

ส่วนที่ 1 จาก 4

วงรอบปรับปรุงสกิล

บท 04–05 ทดสอบว่าสกิล **ใช้ได้** · บทนี้ถามว่าแก้แล้ว **ดีขึ้นจริงไหม**

สกิลใช้ได้ ยังไม่ใช่ สกิลเก่ง

แก้ตามความรู้สึก

- ไม่รู้ว่าดีขึ้นจริงไหม
- แก้จุดหนึ่ง พังอีกจุดหนึ่ง
- สกิลยาวขึ้นเรื่อย ๆ

แก้ด้วยหลักฐาน

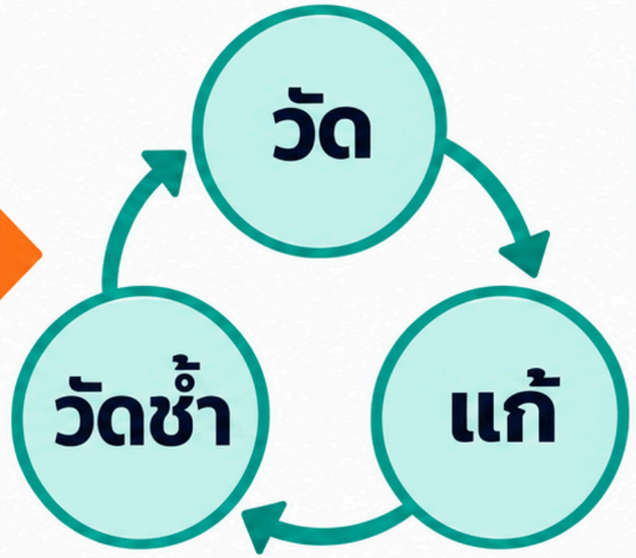

1 · ปัญหา

ถ้าแก้ตามความรู้สึก

ทำแบบนี้	สิ่งที่เกิด
ลองโจทย์เดียว เห็นว่าดีขึ้น	รันซ้ำอีกรอบอาจได้ผลต่างเดิม เพราะ AI ตอบไม่เหมือนกันทุกครั้ง
เพิ่มกติกาเพื่อแก้โจทย์ที่พลาด	โจทย์นั้นผ่าน แต่โจทย์อื่นที่เคยผ่านอาจพัง
เพิ่มกติกาทุกครั้งที่เจอปัญหา	สกิลยาวขึ้น แพงขึ้น โดยไม่รู้ว่ากติกาข้อไหนมีผลจริง

วงรอบปรับปรุงสกิล 6 ขั้น
1
ชุดโจทย์
2
วัด baseline
3
หาสาเหตุ
4
แก้ไม่เกิน 3 จุด
5
วัดซ้ำ
6
ประตูรับ
SKILL.md
v0 → v1 → v2
รุ่นใหม่ต้องผ่านประตู จึงจะได้แทนรุ่นเดิม

2 · วงรอบปรับปรุงสกิล 6 ขั้น

แต่ละขั้นทำอะไร

ขั้น	ทำอะไร	ใช้โทเคน
1 · ชุดโจทย์	เตรียมโจทย์ แบ่ง train / val และเขียนตัวตรวจ	ไม่ใช้
2 · วัด baseline	รันสกิลรุ่นเดิมกับทุกโจทย์ โจทย์ละหลายรอบ	**ใช้**
3 · หาสาเหตุ	อ่านข้อที่พลาดและร่องรอยการทำงานของชุด train	ไม่ใช้
4 · แก้	สร้างรุ่นใหม่ แก้ไม่เกิน 3 จุด	ไม่ใช้
5 · วัดซ้ำ	รันรุ่นใหม่ด้วยเงื่อนไขเดียวกับ baseline ทุกค่า	**ใช้**
6 · ประตูรับ	เทียบสองรุ่น รับหรือไม่รับ แล้ววนกลับไปขั้น 3	ไม่ใช้

2.1 · สกิลมี 4 ส่วน ปรับได้ทุกส่วน

- `description` ให้ AI เรียกสกิลถูกเวลา
- `SKILL.md` กติกาและขั้นตอน
- `scripts/` งานที่ตรวจได้ด้วยโค้ด
- `references/` รายละเอียดที่เปิดเมื่อใช้

> ถ้าสคริปต์ตรวจและเตือนให้ได้ ให้ทำในสคริปต์ ข้อความเตือนมาถึงตรงเวลาที่ต้องแก้พอดี

- **train** ใช้หาข้อบกพร่อง อ่านร่องรอยได้
- **val** ใช้ตัดสินที่ประตูเท่านั้น
- train ขึ้น แต่ val ลง = สกิล**จำโจทย์** (overfit)

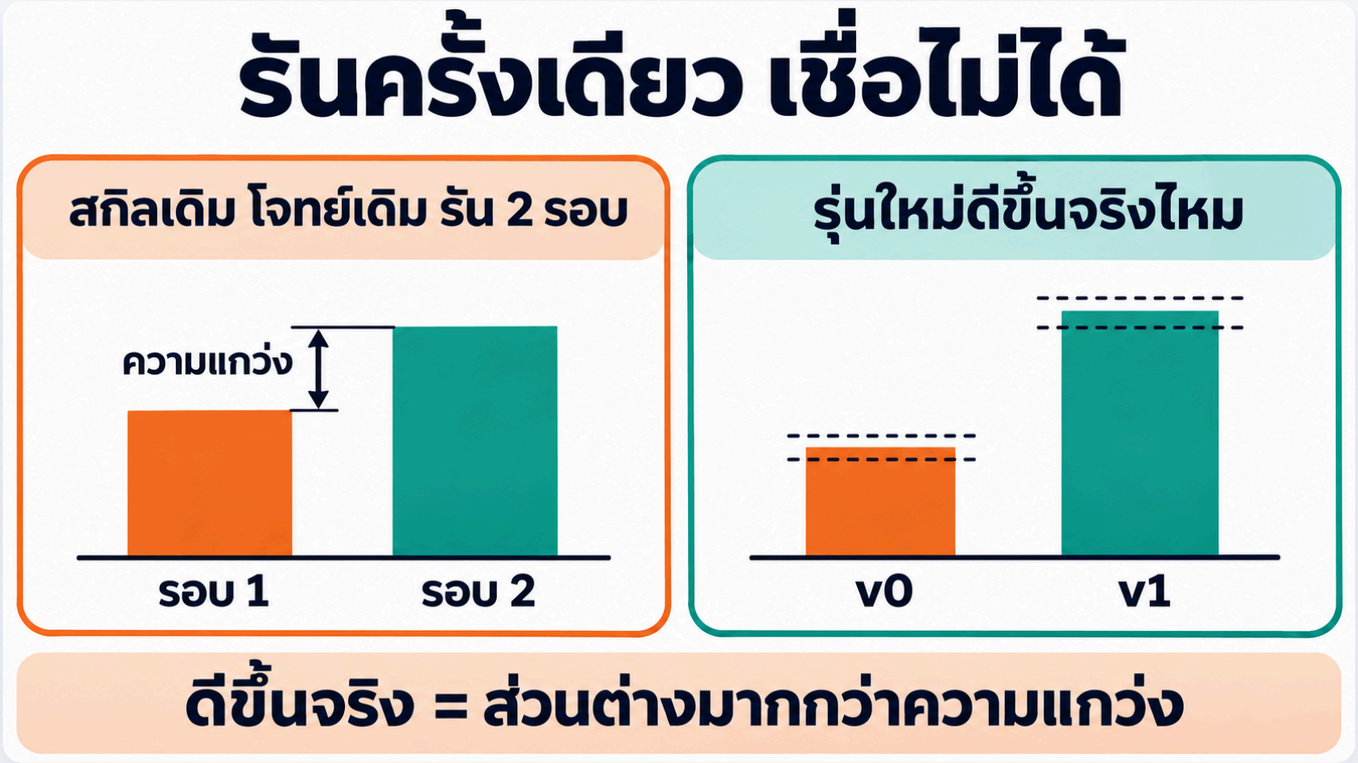

- สกิลเดิม โจทย์เดิม รัน 2 รอบได้คะแนนไม่เท่ากัน
- ส่วนต่างนี้คือ**ความแกว่ง** วัดด้วยคำสั่ง `null`
- รุ่นใหม่ต้องดีขึ้นมากกว่าความแกว่ง จึงนับว่าดีขึ้นจริง

$$\text{ความแกว่งของค่าเฉลี่ย} = \frac{\text{ความแกว่งต่อโจทย์}}{\sqrt{n}}$$

- คะแนน train ไม่ลดเกินเกณฑ์
- คะแนน val ไม่ลดเกินเกณฑ์
- คะแนนรวมดีขึ้นมากกว่าเกณฑ์ **หรือ** คะแนนเท่าเดิม แต่ต้นทุนลด ≥ 10%

> เกณฑ์ = ค่าที่มากกว่าระหว่าง 2 จุด กับความแกว่งของค่าเฉลี่ยของรุ่นเดิม

- ปัญหาอะไร พบกี่รอบ
- ลองแก้อย่างไร ได้ผลหรือไม่
- รอบถัดไปอ่านก่อน ไม่ลองทางที่เคยไม่ได้ผลซ้ำ
- ปัญหาที่พบรอบเดียวยังไม่แก้

6 แนวคิดจากงานวิจัย ก.ย.-ต.ค. 2026

SkillAdam
สมุดปัญหา + จำกัดขนาดการแก้

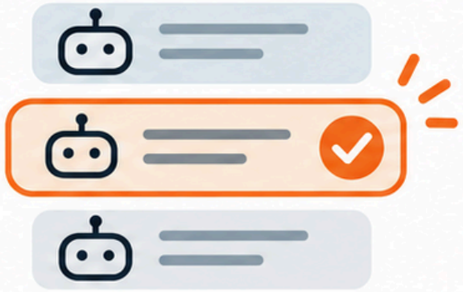

COBRA-Skills
เลือกรุ่นที่ควรวัดก่อน

BiPA
ระวังกำไรปลอมจากความแกว่ง

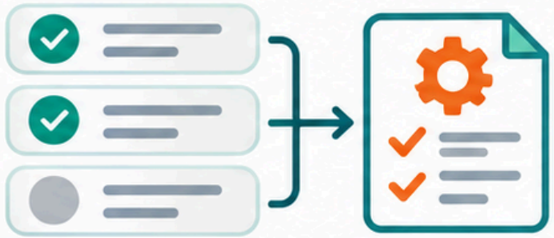

HSE
กลั่นกติกาจากร่องรอยการทำงาน

Skill Revisions
กติกาที่ระบุคำสั่งและไฟล์ได้ผล

WebDev-Skills-Bench
ตรวจเว็บด้วย Playwright

3 · งานวิจัยที่เกี่ยวข้อง (ก.ย.–ต.ค. 2026)

แนวคิดที่นำมาใช้ (1)

งาน	วันที่	แนวคิดหลัก	ใช้ในบทนี้
SkillAdam	8 ก.ย.	issue tracker จำข้อผิดพลาดและทางแก้ที่ลองแล้ว · จำกัดขนาดการแก้	`ISSUES.md` · แก้ไม่เกิน 3 จุด
COBRA-Skills	10 ก.ย.	งบวัดผลจำกัด ใช้ bandit เลือกรุ่นที่ควรวัดเต็มชุด	วัดเฉพาะรุ่นที่มีเหตุผล (ไม่ได้ทำ bandit)
BiPA	27 ต.ค.	กำไรบนชุดเล็กหายเมื่อวัดกับชุดทดสอบ · ต้นทุนมาจากจำนวนรอบมากกว่าความยาวสกิล	`null` · ประตูเทียบความแกว่ง · นับคำสั่ง
HSE	26 ต.ค.	กลั่นสกิลจากร่องรอย แก้ไม่เกิน 3 กติกา ตรวจกับงานที่กันไว้	อ่าน transcript ก่อนแก้ · ชุด val

3 · งานวิจัยที่เกี่ยวข้อง (ก.ย.–ต.ค. 2026)

แนวคิดที่นำมาใช้ (2)

งาน	วันที่	แนวคิดหลัก	ใช้ในบทนี้
Agent Skill Evolution	4 ต.ค.	กติกาที่ได้ผลมักระบุคำสั่งหรือ path ที่รุ่นก่อนไม่เคยพูดถึง	กติกาใหม่ระบุค่าที่ตรวจได้ เช่น "เกิน 60%"
SkillScriptBench	2 ต.ค.	แก้ทั้ง SKILL.md และสคริปต์ โดยไม่ทำของเดิมพัง	แก้สคริปต์ด้วย · ดูข้อตรวจเดิมทุกข้อ
SWE-Skills-Bench (ฉบับ 2)	27 ต.ค.	สกิล 92 จาก 98 ตัวไม่ทำให้ผลต่างอย่างมีนัยสำคัญ	แขน "ไม่มีสกิล"
WebDev-Skills-Bench	24 ส.ค.	วัดสกิลงานเว็บด้วยชุดทดสอบ Playwright	ตัวตรวจเว็บของส่วนที่ 2
claude plugin eval	ก.ย.	รันโจทย์ละ 3 รอบ เทียบกับแขนที่ไม่มีปลั๊กอิน	มีสกิล เทียบ ไม่มีสกิล

ลิงก์ของทุกงานอยู่ใน README หัวข้อ 3 · ตัวเลขเป็นของผู้เขียนงานนั้น

สกิล skill-optimizer มี 6 คำสั่ง
ไม่ใช้โทเคน
ใช้โทเคน
lint
วัดขนาดสกิล
run
รันโจทย์จริง
failures
ดูข้อที่พลาด
report
เทียบรุ่น
null
วัดความแกว่ง
gate
รับ / ไม่รับ
รันผ่านบัญชี yolo ของ base skills

4 · เครื่องมือ: สกิล skill-optimizer

คำสั่งของ `skillopt.py`

คำสั่ง	ทำอะไร	ผลที่ได้
`lint`	วัดขนาดของสกิล	บรรทัดและไบต์ของ SKILL.md · ลิงก์ที่เสีย
`run`	รันสกิลกับทุกโจทย์ รอบละ sandbox ใหม่ (**ใช้โทเคน**)	ผลงาน ร่องรอย ตัวชี้วัด คะแนน
`failures`	แสดงข้อที่พลาด	ข้อตรวจที่ไม่ผ่าน + path ของร่องรอย
`report`	เทียบรุ่น	ตาราง + `results.json`
`null`	วัดความแกว่ง	ต่อโจทย์ และของค่าเฉลี่ย
`gate`	ตัดสิน	ACCEPT / REJECT พร้อมเหตุผล
`grade`	ตรวจผลงานเดิมซ้ำหลังแก้ตัวตรวจ	คะแนนใหม่ ไม่ต้องรันโจทย์

5 · ภาพรวมขั้นตอนการทดลอง

9 ขั้น 157 รอบ

ขั้น	ทำอะไร	ผลจริง	รอบ
1	เตรียมชุดโจทย์และตัวตรวจของ dag-planner	โจทย์ 8 ข้อ ข้อตรวจ 10 ข้อ	0
2	วัดเส้นฐาน v0 และความแกว่ง	94.7% · ความแกว่ง 1.0 จุด	16
3	หาสาเหตุ เขียนสมุดปัญหา	2 สาเหตุที่พบซ้ำ	0
4	แก้เป็น v1 วัดซ้ำ ประตูรับ	100% · ACCEPT	16
5	ลองลดต้นทุนเป็น v2	ค่าใช้จ่ายไม่ลด · REJECT	16
6	ให้ Claude สร้างสกิล web-builder	SKILL.md + verify.cjs ใน 94 วินาที	1
7	สร้างชุดโจทย์เว็บ + ตัวตรวจ Playwright	ชุดแรกง่ายไป · ชุดที่ 2 มี 32 ข้อตรวจ	36
8	วัด: ไม่มีสกิล เทียบ v0	คะแนนเท่ากัน · คำสั่ง 19.0 → 11.0	48
9	ปรับสกิล 2 รอบ	v1 REJECT · v2 ACCEPT	24

5 · ภาพรวมขั้นตอนการทดลอง

โฟลเดอร์งาน

```
07_Skill_Optimization/
├── skills/skill-optimizer/        ← สกิลของบทนี้: SKILL.md · scripts/skillopt.py · references/
├── part1_dag-planner/
│   ├── evals/                     ← suite.json (8 โจทย์) · grade.py · results.json
│   ├── versions/v0 v1 v2          ← v0 = สกิลจากบท 05 · v1 = ผ่านประตู · v2 = ไม่ผ่าน
│   └── ISSUES.md
└── part2_web-builder/
    ├── prompt_create_v0.txt       ← พรอมต์ที่ใช้สร้างสกิลรุ่นแรก
    ├── evals_easy/                ← ชุดโจทย์ชุดแรก (ง่ายไป)
    ├── evals/                     ← suite.json (6 โจทย์) · harness.cjs · checks/ · ref/
    ├── versions/v0 v1 v2          ← v0 = Claude สร้าง · v1 = ไม่ผ่าน · v2 = ผ่านประตู
    └── ISSUES.md
```

- ต้องมี container `multi-account` จากบท 03 และล็อกอิน Claude อย่างน้อย 2 บัญชี
- เปิด session ที่โฟลเดอร์ `07_Skill_Optimization` ทุกขั้นวางพรอมต์อย่างเดียว

ส่วนที่ 2 จาก 4

ปรับปรุงสกิลเดิม dag-planner

สกิลจากบท 05 ที่ต่อยอดจาก base skills · **v0 94.7%** → **v1 100%** และ v2 ที่ไม่ผ่านประตู

ขั้นที่ 1 เตรียมชุดโจทย์และตัวตรวจ

ชุดโจทย์ suite.json

ตัวตรวจ grade.py

10 ข้อ ตรวจด้วยโค้ด

sandbox ต่อรอบ

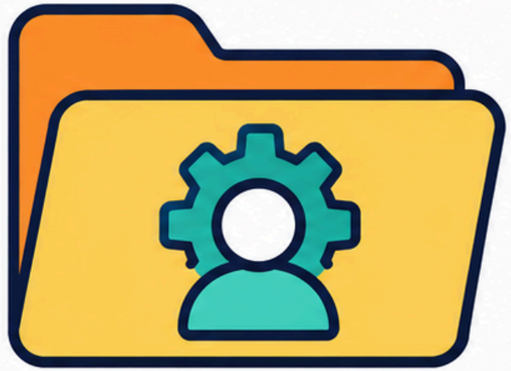

สกิลถูกคัดลอกมาใหม่ทุกรอบ

ยังไม่ใช้โทเคน

ขั้นที่ 1 · เตรียมชุดโจทย์และตัวตรวจ

โจทย์ 8 ข้อ

ชุด	โจทย์	agent	บัญชี	จุดที่วัด
train	t1 จองห้องประชุมห้องสมุด	4	Claude 2 · Codex 2	กรณีปกติ
train	t2 เว็บประกาศข่าวโรงเรียน	2	Claude 2	ไม่มีบัญชี Codex
train	t3 ระบบสมาชิกฟิตเนส	3	Claude 2 · Codex 1	บล็อกหลายบัญชีไม่เกิน 3
train	t4 สั่งอาหาร food truck	4	Claude 2 · Codex 1	**ภาพของรายการ**ต้องรอข้อมูล
val	v1 นัดหมายคลินิกสัตว์	4	Claude 2 · Codex 2	กรณีปกติ
val	v2 แจ้งซ่อมหอพัก	2	Codex 2	ไม่มีบัญชี Claude
val	v3 ร้านสหกรณ์ชุมชน	3	Claude 1 · Codex 2	**ภาพของรายการ**ต้องรอข้อมูล
val	v4 แพลตฟอร์มแบบทดสอบ	4	Claude 2 · Codex 2	โควตาต่ำ

ชุด val มีโจทย์แบบเดียวกับ train ทุกแบบ แต่เป็นคนละงาน

ขั้นที่ 1 · เตรียมชุดโจทย์และตัวตรวจ

ตัวตรวจ `grade.py` 10 ข้อ

ข้อตรวจ	ผ่านเมื่อ
`files` · `dag_valid` · `block_count`	มีไฟล์ครบ · `dag` ไม่มี ERROR · 8–12 บล็อก
`structure` · `output_done`	บล็อกสุดท้ายเป็น exclusive · ทุกบล็อกมี output และ done
`constraints` · `all_scheduled`	ใช้จำนวน agent และบัญชีตามโจทย์ · ทุกบล็อกมีบัญชีรับ
`selective`	บล็อกหลายบัญชีไม่เกิน 1 ใน 3
`parallel`	สายวิกฤตไม่เกิน 60% ของงานรวม
`image_data`	บล็อกภาพของรายการรอบล็อกข้อมูล (เฉพาะ t4 และ v3)

ตัวตรวจไม่เชื่อคำตอบของเอเจนต์ อ่าน `blocks.json` แล้วให้สคริปต์ของ v0 วางแผนซ้ำ · คะแนน = ข้อที่ผ่าน ÷ ข้อที่ตรวจ

ขั้นที่ 1 · วางพรอมต์

เตรียมการทดลอง (ไม่ใช้โทเคน)

```
เตรียมการทดลอง skill optimization ใน container multi-account ทำผ่าน docker เท่านั้น ห้ามลบ หยุด หรือสร้าง container / volume ห้ามแตะ credential และห้ามล็อกอินแทนผม
- คัดลอก ../05_DAG_Planner/base_skills ไปที่ /workspace/05_DAG_Planner/base_skills
- คัดลอกโฟลเดอร์ skills part1_dag-planner และ part2_web-builder ของโฟลเดอร์นี้ไปที่ /workspace/07_Skill_Optimization/ (ไม่ต้องคัดลอกโฟลเดอร์ runs)
- อ่าน /workspace/07_Skill_Optimization/skills/skill-optimizer/SKILL.md แล้วใช้สกิลนี้ตลอดการทดลอง
- สั่ง lint กับสกิล part1_dag-planner/versions/v0 และตรวจว่าบัญชี yolo2 กับ yolo3 พร้อมใช้
- เปิด part1_dag-planner/evals/suite.json แล้วสรุปว่ามีกี่โจทย์ ชุด train และ val อย่างละกี่ข้อ และตัวตรวจ grade.py ตรวจอะไรบ้าง
ยังไม่ต้องรันโจทย์ ตอบเป็นตารางสั้น ๆ แล้วหยุด
```

> ผลจริง: SKILL.md ของ v0 ยาว 85 บรรทัด 10,836 ไบต์ · ไม่มีลิงก์เสีย

ขั้นที่ 2 วัดเส้นฐานของสกิลเดิม (v0)

ขั้นที่ 2 · วางพรอมต์

วัดเส้นฐาน v0 (16 รอบ)

```
วัดเส้นฐานของสกิล dag-planner รุ่น v0 ด้วยสกิล skill-optimizer ใน container multi-account
- ชุดโจทย์ /workspace/07_Skill_Optimization/part1_dag-planner/evals สกิล part1_dag-
planner/versions/v0 ตั้งชื่อรุ่นว่า v0
- รันทุกโจทย์ โจทย์ละ 2 รอบ บนบัญชี yolo2 และ yolo3 (16 รอบ ใช้โทเคนจริง)
- เสร็จแล้ววัดความแกว่งของ v0
ตอบ: ตารางจาก report · ความแกว่งของค่าเฉลี่ย · ข้อตรวจที่ผ่านไม่ครบ ตัวเลขต้องมาจากคำสั่งของสกิลเท่านั้น
```

ขั้นที่ 2 · ผลจริง (16 รอบ · sonnet/medium)

v0 ได้ 94.7%

ชุด	รอบ	คะแนน	ได้เต็มทุกข้อ	คำสั่ง	ค่าใช้จ่าย	`parallel`	`image_data`
train	8	**94.7%**	4/8	4.4	$0.16	5/8	1/2
val	8	**94.7%**	4/8	4.2	$0.15	6/8	0/2

- 8 จาก 10 ข้อตรวจผ่านครบ 16/16 รอบ สกิลเดิมดีอยู่แล้ว
- จุดอ่อนซ้ำกัน 2 ข้อ ทั้งในชุด train และ val
- ความแกว่งของค่าเฉลี่ย **1.0 จุด** รุ่นใหม่ต้องดีขึ้นมากกว่าเกณฑ์ 2.0 จุด

ขั้นที่ 3 หาสาเหตุจากร่องรอย

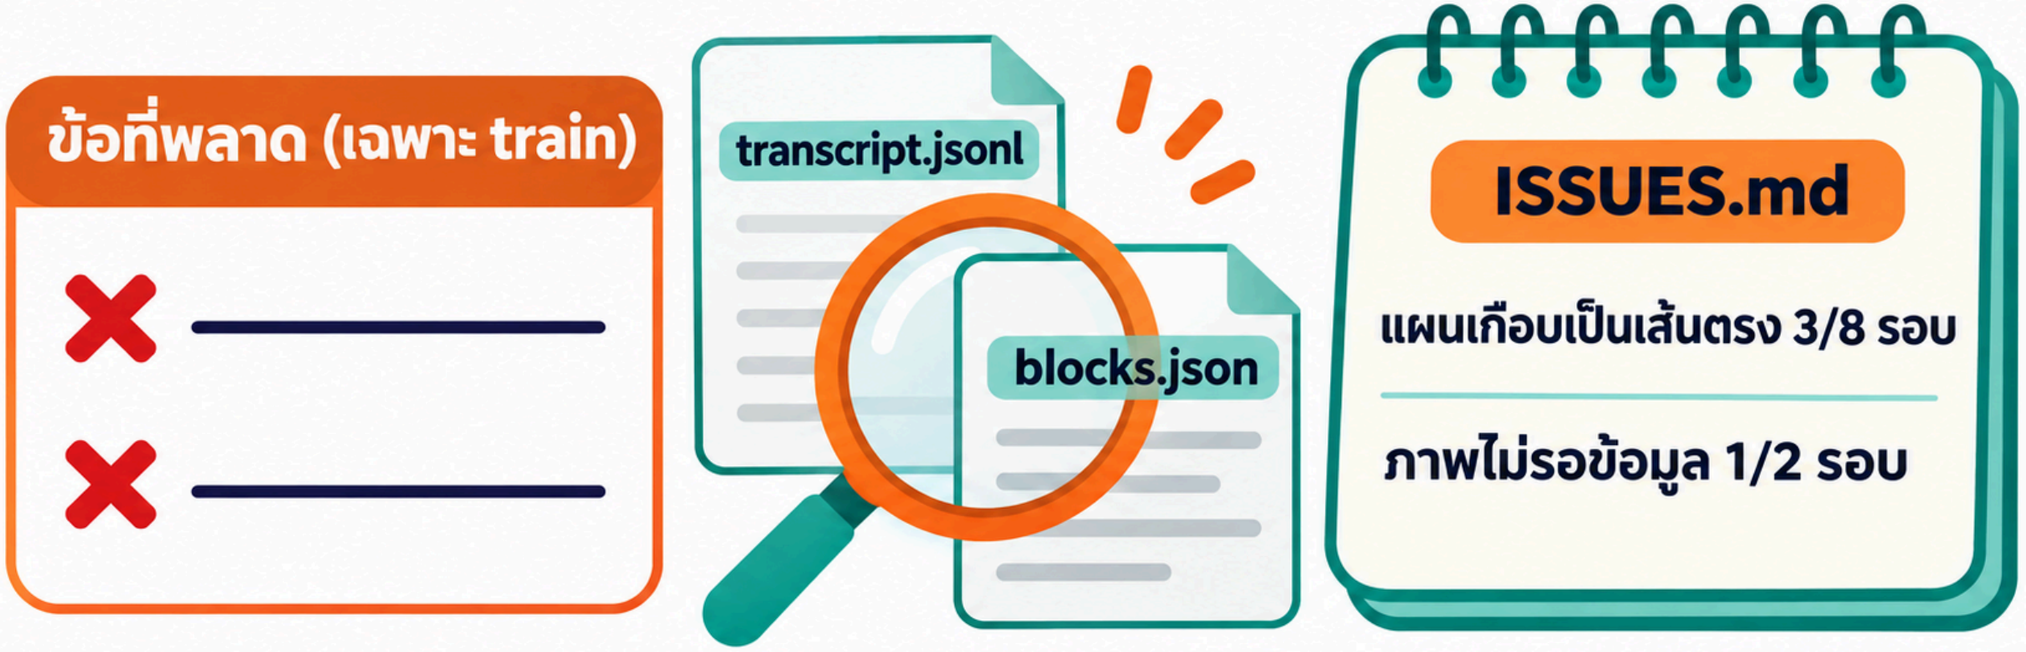

แก้เฉพาะสาเหตุที่พบซ้ำ

ขั้นที่ 3 · วางพรอมต์

หาสาเหตุ (ไม่ใช้โทเคน)

```
หาสาเหตุของข้อที่ v0 พลาด ด้วยสกิล skill-optimizer (ยังไม่แก้สกิล)
- ดูเฉพาะชุด train: สั่ง failures แล้วเปิด transcript.jsonl และ blocks.json ของรอบที่พลาด
- เขียนสมุดปัญหาที่ /workspace/07_Skill_Optimization/part1_dag-planner/ISSUES.md ตามรูปแบบของสกิล
ตอบ: ตาราง ปัญหา | พบกี่รอบ | สาเหตุ | ทางแก้ที่เสนอ (ไม่เกิน 3 ข้อ)
```

ขั้นที่ 3 · ผลจริง

ชุด train พลาด 4 จาก 8 รอบ รวมเป็น 2 สาเหตุ

ปัญหา	พบ	หลักฐานจากผลงาน	สาเหตุในสกิล
แผนเกือบเป็นเส้นตรง	3/8 รอบ	t3 รอบ 1: สายวิกฤต 9.6 จากงานรวม 13.8 (70%)	กติกาบอกแค่ "รอเท่าที่จำเป็น" ไม่มีตัวเลขให้ตรวจ และ `dag` ไม่เตือน
ภาพของรายการไม่รอข้อมูล	1/2 รอบ	t4 รอบ 1: บล็อกรูปอาหาร B03 B04 ไม่มี `depends_on`	สกิลไม่มีกติกาข้อนี้ (บทเรียนเหมียวช็อปของบท 05)

ขั้นที่ 4 แก้ 2 จุด วัดซ้ำ ผ่านประตูรับ

train และ val ดีขึ้นเท่ากัน +5.3 จุด

ขั้นที่ 4 · วางพรอมต์

แก้เป็น v1 แล้ววัดซ้ำ (16 รอบ)

```
ปรับปรุงสกิล dag-planner จาก v0 เป็น v1 ตามสมุดปัญหา ด้วยสกิล skill-optimizer
- คัดลอก versions/v0 เป็น versions/v1 แล้วแก้ไม่เกิน 3 จุด ให้สคริปต์เตือนเองก่อนเพิ่มกติกา ห้ามใส่ชื่อหรือคำตอบของโจทย์ลงในสกิล
- รัน v1 ด้วยเงื่อนไขเดียวกับ v0 ทุกค่า (16 รอบ) แล้วสั่ง gate เทียบ v0 กับ v1
- ถ้าข้อตรวจใดของ v1 แย่ลง ให้เปิดผลงานของรอบนั้นดูก่อนว่าเป็นความผิดของสกิลหรือของตัวตรวจ
ตอบ: จุดที่แก้ · ตารางเทียบ v0 กับ v1 · ผลประตู แล้วอัปเดต ISSUES.md
```

ขั้นที่ 4 · จุดที่แก้ (2 จุด)

ให้คำสั่ง `dag` เตือนเอง

```
OK 10 บล็อก · สายวิกฤต B01 → B04 → B05 → B07 → B08 → B10 · ยาว 9.6M tok
WARN สายวิกฤต … ยาว 70% ของงานรวม (เกิน 60%) = แผนเกือบเป็นเส้นตรง ทำขนานได้น้อย
     → ตัด depends_on ที่บล็อกบนสายนี้ไม่ได้อ่านไฟล์ผลจริง หรือแบ่งบล็อก L แล้วสั่ง dag ซ้ำ
WARN B02 (image) ไม่รอบล็อกข้อมูลใดเลย: ถ้าเป็นภาพของรายการ (สินค้า · เมนู · ข่าว)
     ต้อง depends_on บล็อกที่กำหนดรายการนั้น · โลโก้และไอคอนทั่วไปไม่ต้องแก้
```

- จุดที่ 1: `WARN` เมื่อสายวิกฤตเกิน 60% + ตัวเลข 60% ในกติกา + ขั้นตอนสั่งให้อ่าน `WARN`
- จุดที่ 2: `WARN` เมื่อบล็อก `image` ไม่รอข้อมูล + กติกา 1 ข้อ
- SKILL.md ยาวขึ้น 10,836 → 11,685 ไบต์ (+8%)

ขั้นที่ 4 · ผลจริง: v0 เทียบ v1 (และ v2)

✻ Claude · ส่วนที่ 1 · ผลจริง 10 พ.ย. 2026 (จัดหน้าจาก results.json)

สกิล dag-planner: 3 รุ่น วัดด้วยโจทย์ชุดเดียวกัน (8 โจทย์ × 2 รอบ = 16 รอบต่อรุ่น)

รุ่น	คะแนน train	คะแนน val	ได้เต็มทุกข้อ	ข้อ parallel	ข้อ image_data	เวลา (วินาที)	คำสั่ง	ค่าใช้จ่ายต่อรอบ	ประตูรับ
v0	94.7%	94.7%	8/16	11/16	1/4	114	4.3	$0.154	เส้นฐาน
v1	**100.0%**	**100.0%**	16/16	16/16	4/4	160	5.0	$0.162	ACCEPT
v2	**100.0%**	**100.0%**	16/16	16/16	4/4	179	4.9	$0.161	REJECT

v1 = แก้ 2 จุด (คำสั่ง `dag` เตือนเมื่อสายวิกฤตเกิน 60% · ภาพของรายการต้องรอบล็อกข้อมูล) · v2 = ย้ายเนื้อหาออกจาก SKILL.md ให้สั้นลง 14%
ความแกว่งของค่าเฉลี่ยของ v0 = 1.0 จุด · เกณฑ์ของประตู = 2.0 จุด · ผู้ทำโจทย์ sonnet/medium บนบัญชี yolo2 และ yolo3

ขั้นที่ 4 · ผลของคำสั่ง gate

ACCEPT

```
ความแกว่งของ v0 เอง (A/A): ต่อโจทย์ 2.8 จุด · ของค่าเฉลี่ย 1.0 จุด → เกณฑ์ = ค่าที่มากกว่าระหว่างค่านี้กับ eps 2.0
train: 94.7% → 100.0% (+5.3) · ค่าใช้จ่าย $0.16 → $0.16 · คำสั่ง 4.4 → 4.8
val: 94.7% → 100.0% (+5.3) · ค่าใช้จ่าย $0.15 → $0.17 · คำสั่ง 4.2 → 5.2
  ✓ คะแนนรวมดีขึ้น +5.3 จุด มากกว่าความแกว่ง 2.0 จุด
ผล: ACCEPT ✅ รับ v1 แทน v0
```

- ชุด val ที่ไม่ได้ใช้ตอนแก้ ขึ้น +5.3 จุดเท่ากับ train จึงไม่ใช่การจำโจทย์
- ราคาที่จ่าย: output token +20% · คำสั่ง 4.3 → 5.0 · ค่าใช้จ่าย +5%
- ข้อตรวจ 8 ข้อที่เคยผ่านครบ ยังผ่านครบ

ตัวตรวจก็ผิดได้: อ่านร่องรอยก่อนเชื่อคะแนน

ห้ามแก้ตัวตรวจเพื่อให้รุ่นใหม่ผ่าน

ขั้นที่ 4 · บทเรียนจากของจริง

รอบแรก v1 ได้ `image_data` 0/4 แย่กว่า v0

รอบของ v1	บล็อกภาพในแผน	ตัวตรวจรุ่นแรก
t4 รอบ 1	B04 โลโก้ (ไม่รอ) · B05 B06 รูปอาหาร ← B02 ข้อมูลเมนู	ไม่ผ่าน เพราะ B04
t4 รอบ 2	B03 โลโก้ร้าน (ไม่รอ) · B05 B06 รูปอาหาร ← B02	ไม่ผ่าน เพราะ B03
v3 รอบ 1	B03 โลโก้สหกรณ์ (ไม่รอ) · B05 B06 รูปสินค้า ← B02	ไม่ผ่าน เพราะ B03
v3 รอบ 2	B06 โลโก้ร้าน (ไม่รอ) · B05 รูปสินค้า ← B02	ไม่ผ่าน เพราะ B06

รูปอาหารและรูปสินค้ารอข้อมูลครบทุกรอบ ที่ถูกนับผิดคือ**โลโก้** → แก้ `grade.py` แล้วตรวจซ้ำ**ทุกรุ่น**: v0 ยังเป็น 1/4 · v1 เป็น 4/4

ขั้นที่ 5 ลองลดต้นทุน: ไม่ผ่านประตู

สั้นลง 14%

คะแนนเท่าเดิม 100%

ค่าใช้จ่ายไม่ลดลง

ใช้ v1 ต่อ

ไม่ผ่านก็ได้ความรู้: ต้นทุนมาจากจำนวนรอบ ไม่ใช่ความยาว

ขั้นที่ 5 · วางพรอมต์

ลองลดต้นทุนเป็น v2 (16 รอบ)

```
ลองลดต้นทุนของสกิล dag-planner: สร้าง v2 จาก v1 โดยย้ายเนื้อหาที่งานวางแผนไม่ได้ใช้ออกจาก SKILL.md ไปไว้ใน references ห้ามเปลี่ยนกติกา
รัน v2 ด้วยเงื่อนไขเดิม (16 รอบ) แล้วสั่ง gate เทียบ v1 กับ v2 ถ้าไม่ผ่านให้ใช้ v1 ต่อ และจดผลลง ISSUES.md
ตอบ: ขนาด SKILL.md ก่อนและหลังจาก lint · ตารางเทียบ · ผลประตูพร้อมเหตุผล
```

ขั้นที่ 5 · ผลจริง

สั้นลง 14% แต่ค่าใช้จ่ายลดไม่ถึง 1%

รุ่น	SKILL.md	คะแนน	คำสั่ง	ค่าใช้จ่ายต่อรอบ	output token	ประตู
v1	86 บรรทัด · 11,685 ไบต์	100%	5.0	$0.162	4,292	ใช้ต่อ
v2	74 บรรทัด · 10,021 ไบต์	100%	4.9	$0.161	4,221	REJECT

- ค่าใช้จ่ายของรอบหนึ่งมาจาก**จำนวนครั้งที่เอเจนต์ทำงาน** ไม่ใช่ความยาวของ SKILL.md
- ตรงกับที่ BiPA รายงาน
- ไม่ผ่านก็ไม่เสียหาย: ใช้ v1 ต่อ และจดไว้ว่าทางนี้ไม่ได้ผล

ส่วนที่ 1 · สรุปเป็นภาพ (ข้อมูลจริง)

✻ **Claude** · dag-planner · ข้อมูลจริงจาก results.json

4 · ลองลดต้นทุน เป็น v2

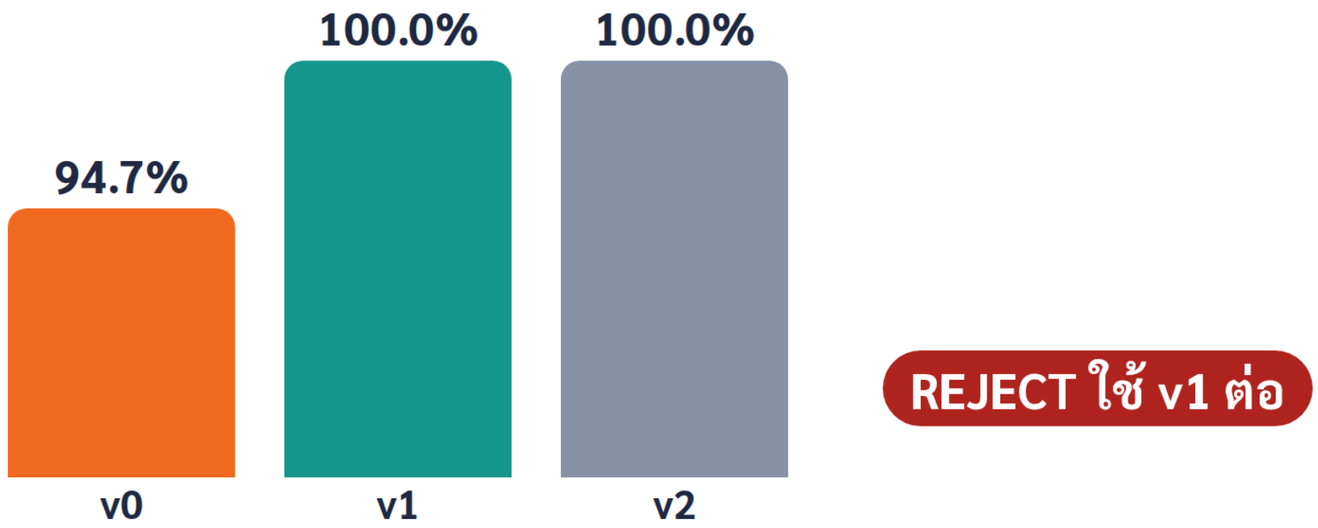

v2 สั้นลง 14% คะแนนเท่าเดิม แต่ค่าใช้จ่าย $0.162 → $0.161 ไม่ลดถึง 10%

แกนตั้งเริ่มที่ 85% · คะแนนรวม 16 รอบต่อรุ่น

ภาพเคลื่อนไหวทีละขั้นอยู่ใน README (img/gif-part1-loop.gif)

ส่วนที่ 3 จาก 4

สร้างสกิลใหม่ web-builder

สร้างเว็บจาก brief แล้วตรวจด้วย **Playwright** · เริ่มจากไม่มีสกิล แล้วปรับด้วยวงรอบเดียวกัน

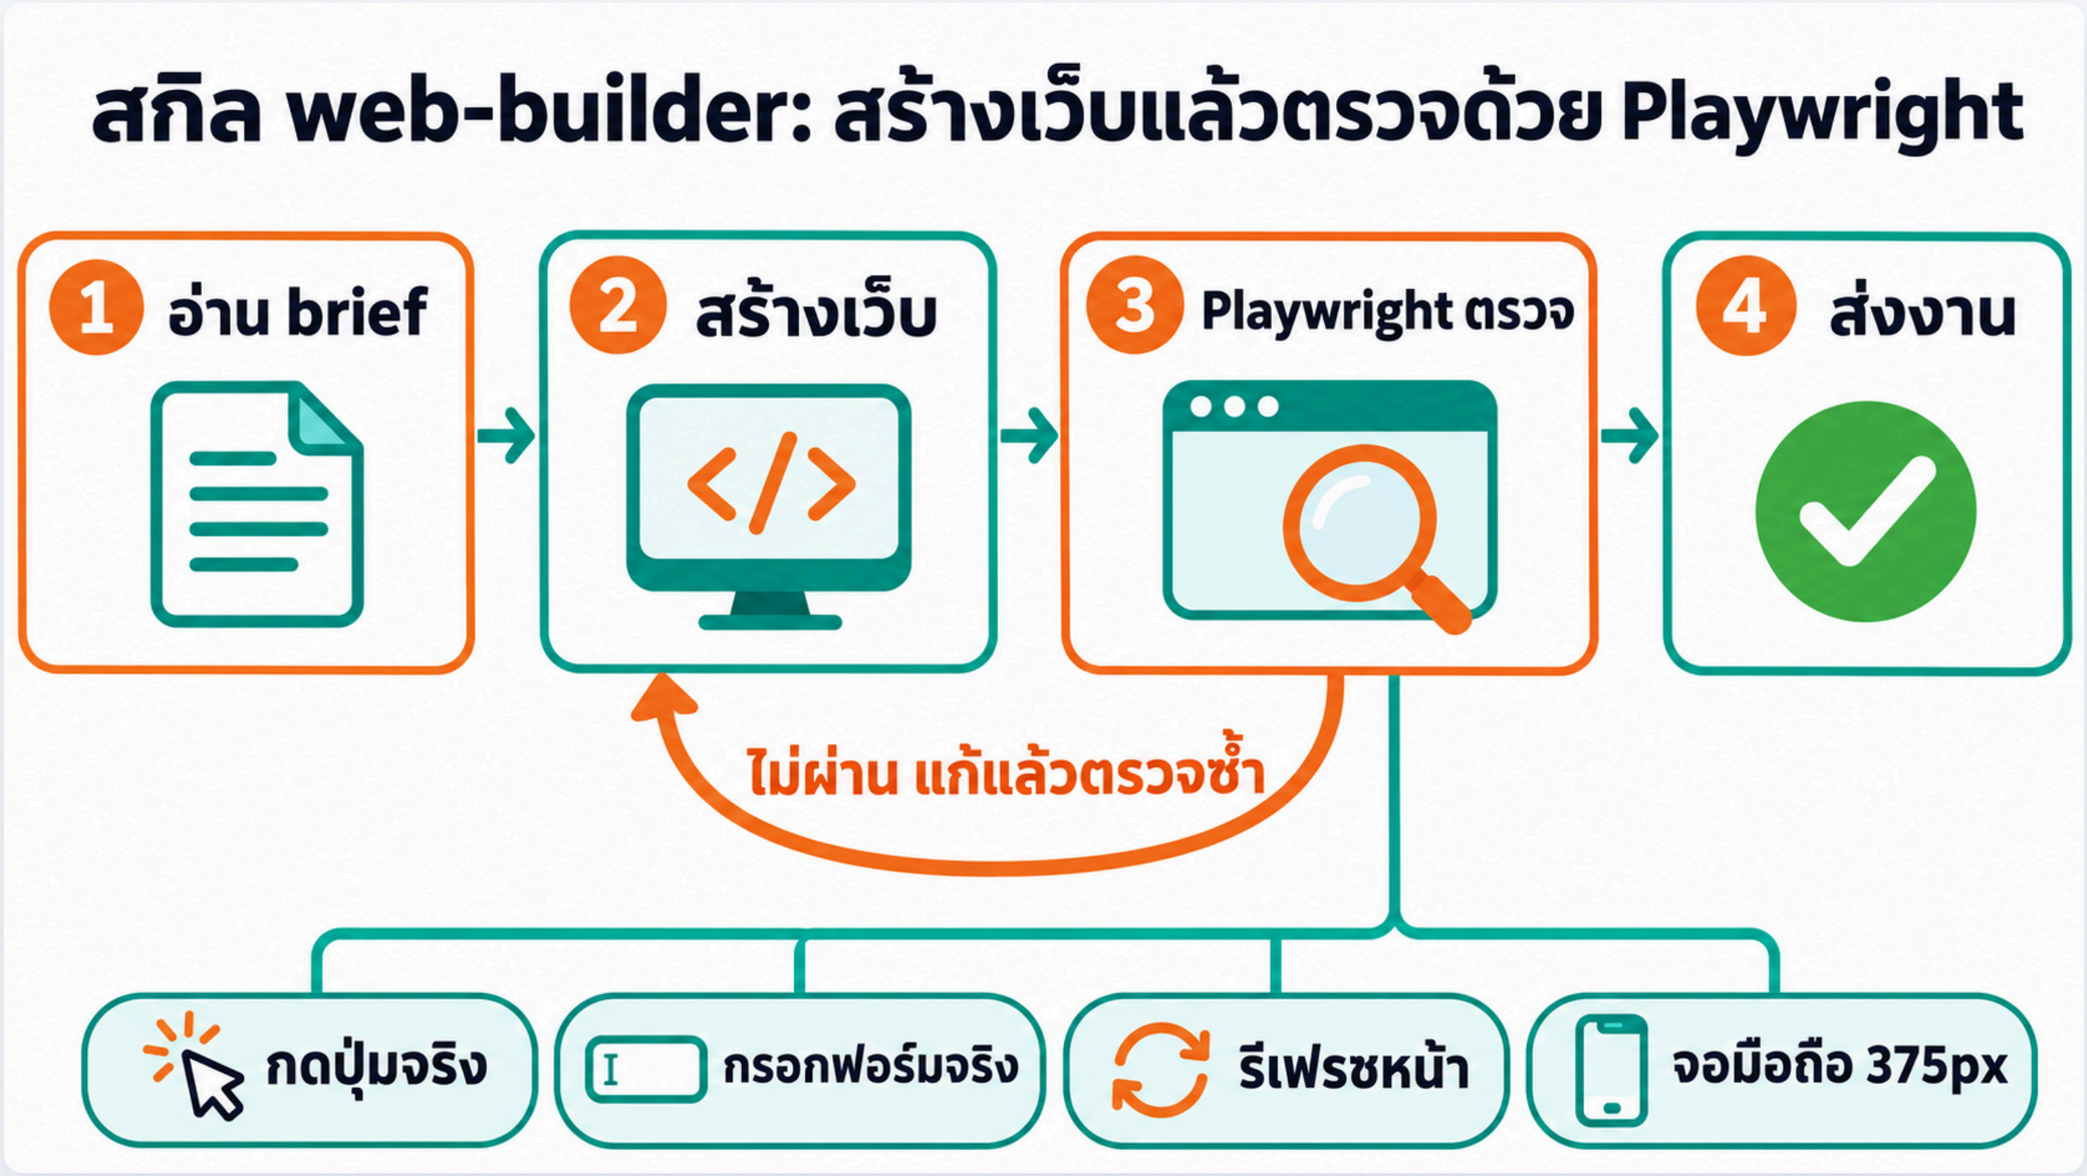
สกิล web-builder: สร้างเว็บแล้วตรวจด้วย Playwright
1 อ่าน brief
2 สร้างเว็บ
3 Playwright ตรวจ
4 ส่งงาน
ไม่ผ่าน แก้แล้วตรวจซ้ำ
กดปุ่มจริง
กรอกฟอร์มจริง
รีเฟรชหน้า
จอมือถือ 375px

ขั้นที่ 6 ให้ Claude สร้างสกิลรุ่นแรก

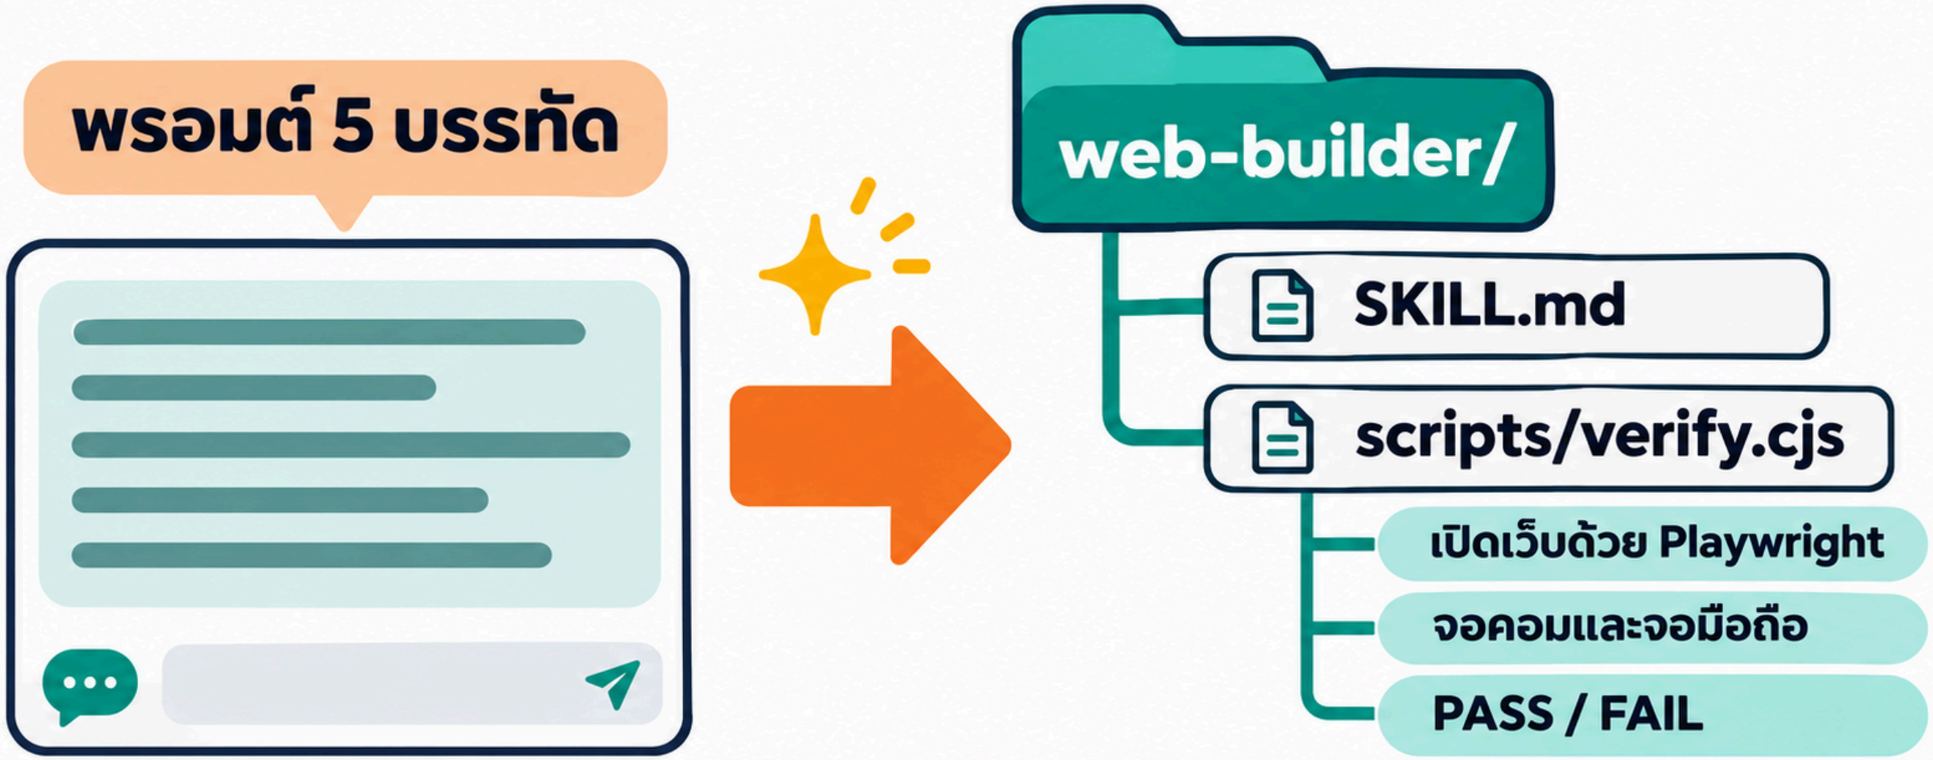

รุ่นแรก = v0 ยังไม่รู้ว่าดีแค่ไหน

ขั้นที่ 6 · วางพรอมต์

สร้างสกิลรุ่นแรก (v0)

```
ช่วยสร้างสกิลชื่อ web-builder สำหรับ AI coding agent
สกิลนี้ใช้เมื่อผู้ใช้ให้ brief ของเว็บไซต์: เอเจนต์สร้างเว็บ static หน้าเดียวไว้ที่ ./site/index.html (HTML CSS JavaScript
ล้วน ไม่มี server ไม่มีขั้น build) แล้วใช้ Playwright เปิดเว็บเพื่อตรวจว่าทำงานจริงก่อนส่งงาน
สร้างไว้ที่ ./skills/web-builder (SKILL.md และ scripts ถ้าจำเป็น) สกิลต้องใช้ได้เมื่อถูกคัดลอกไปวางที่โฟลเดอร์ใดก็ได้
เครื่องนี้มี node และมี playwright อยู่ที่ $(npm root -g)/@playwright/mcp/node_modules/playwright (Chromium
ติดตั้งแล้ว ต้องเปิดด้วย --no-sandbox)
ทดสอบสั้น ๆ ว่าสคริปต์ของสกิลรันได้ แล้วสรุปไฟล์ที่สร้างและหยุด
```

ผลจริง: opus/medium · 94 วินาที · $0.39 · ได้ `SKILL.md` 75 บรรทัด และ `verify.cjs` 170 บรรทัด
`require('playwright')` ตรง ๆ หาไม่เจอใน container ของวิชานี้ จึงต้องบอกตำแหน่งในพรอมต์

วัดสกิลสร้างเว็บ ด้วยชุดตรวจที่เอเจนต์ไม่เคยเห็น

คะแนน = สัดส่วนข้อที่ผ่าน

ขั้นที่ 7 ชุดโจทย์ง่ายไป วัดอะไรไม่ได้

ชุดแรก

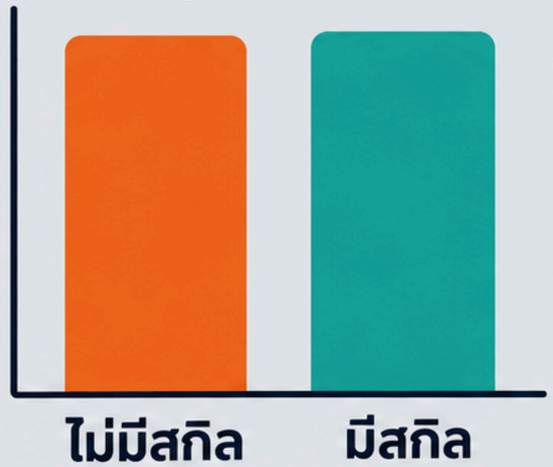

ได้เกือบเต็มทั้งคู่

ทำโจทย์
ให้ยากขึ้น

ชุดใหม่

- กติกาธุรกิจหลายข้อ
- ข้อตรวจ 32 ข้อต่อโจทย์
- มีเว็บอ้างอิงไว้ตรวจตัวตรวจ

ข้อตรวจที่ผ่านทุกครั้ง ไม่ได้วัดอะไร

ขั้นที่ 7 · ชุดแรก (6 โจทย์ขนาดเล็ก)

ไม่มีสกิลก็ได้เกือบเต็ม

แขน	รอบ	คะแนน	ได้เต็มทุกข้อ	คำสั่ง	คำสั่งล้ม
sonnet · ไม่มีสกิล	12	98.5%	10/12	7.7	2.0
sonnet · สกิล v0	12	97.0%	8/12	4.4	0.2
haiku · ไม่มีสกิล	12	99.6%	11/12	23.7	5.2

ข้อตรวจที่ผ่านทั้งตอนมีและไม่มีสกิล ไม่ได้วัดอะไร → ทำโจทย์ให้ยากขึ้น

ขั้นที่ 7 · ชุดที่ใช้จริง

2 แบบ แบบละ 3 ร้าน ตัวเลขต่างกันทั้งหมด

ชุด	โจทย์	กติกาที่ต้องทำให้ถูก
train	t1 ร้านกาแฟ · t3 ร้านขนมปัง	จำนวนต่อรายการ · โค้ดส่วนลด 2 แบบ · ค่าส่งคิดหลังหักส่วนลด · ปัดครึ่งสตางค์ขึ้น · เลขที่ออเดอร์ · จำค่าหลังรีเฟรช
train	t2 ห้องประชุม · t4 สนามแบด	ความจุ · เวลาปิด · เวลาซ้อน (ชนขอบได้) · ราคาวันหยุดและจองยาว · เรียงรายการ · ยกเลิก
val	v1 ร้านต้นไม้ · v2 ห้องซ้อมดนตรี	แบบเดียวกัน ตัวเลขชุดใหม่

กลุ่มข้อตรวจ (32 ข้อต่อโจทย์)	ตัวอย่าง
เฉพาะโจทย์ `f_*` 17–20 ข้อ	โค้ดลด 15% กับยอด ฿59.50 ต้องลด ฿8.93
ความทนทาน `g_*`	localStorage เสียแล้วยังใช้ได้ · ข้อความยาวไม่ดันจอล้น
WCAG 2.2 AA `a_*`	contrast ≥ 4.5:1 · เห็นวงโฟกัส · `aria-invalid`

ขั้นที่ 7 · ตรวจตัวตรวจก่อนใช้

เว็บอ้างอิงใน `evals/ref`

- เขียนเว็บตามสเปกเอง 2 ไฟล์: ร้านค้า และระบบจอง
- รันตัวตรวจกับเว็บอ้างอิงต้องได้ **32/32 ทั้ง 6 โจทย์** ก่อนใช้กับงานของเอเจนต์
- ถ้าเว็บอ้างอิงไม่ผ่าน แปลว่าตัวตรวจหรือสเปกผิด

> พบจริง 1 จุดด้วยวิธีนี้: ช่อง `type="date"` ถูกตัดสินว่าไม่มีวงโฟกัส ทั้ง 3 โจทย์จอง

ขั้นที่ 8 วัด: ไม่มีสกิล เทียบ มีสกิล v0

ไม่มีสกิล

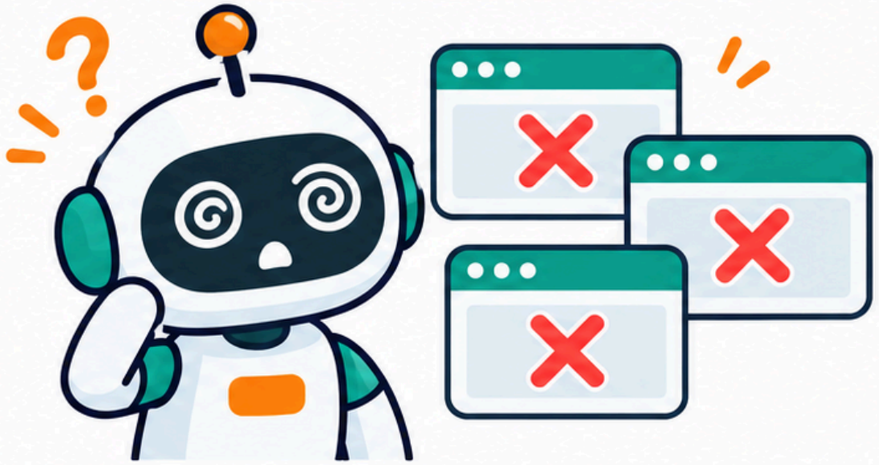

19.0 คำสั่งต่อรอบ

คำสั่งล้ม 4.5 ครั้ง

มีสกิล v0

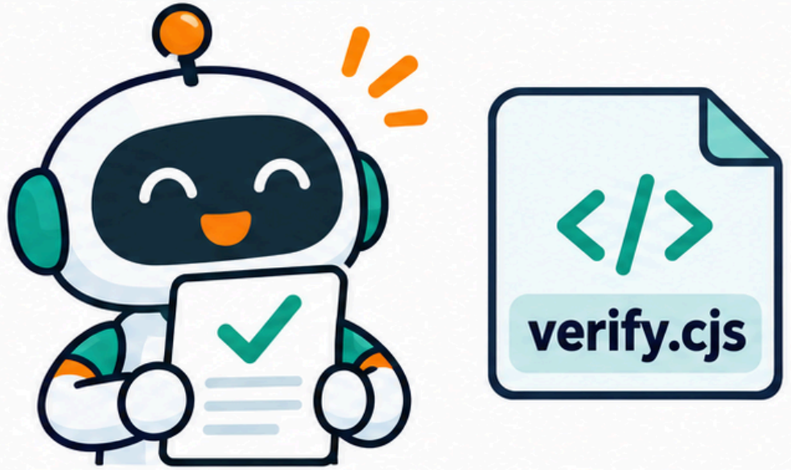

11.0 คำสั่งต่อรอบ

คำสั่งล้ม 0.3 ครั้ง

คะแนนเท่ากัน 99.7% สกิลช่วยที่วิธีทำงาน

ขั้นที่ 8 · วางพรอมต์

วัด 2 แขนของ haiku (24 รอบ)

```
วัดสกิล web-builder รุ่น v0 เทียบกับการไม่ใช้สกิล ด้วยสกิล skill-optimizer ใน container multi-account
- ชุดโจทย์ /workspace/07_Skill_Optimization/part2_web-builder/evals สกิล part2_web-builder/versions/v0
- ผู้ทำโจทย์ haiku/low รัน 2 แขน: ไม่มีสกิล (ชื่อรุ่น h-noskill) และมีสกิล (ชื่อรุ่น h-v0) แขนละ 6 โจทย์ × 2 รอบ บนบัญชี yolo2 และ yolo3 (24 รอบ ใช้โทเคนจริง)
- เสร็จแล้ววัดความแกว่งของ h-v0
ตอบ: ตารางจาก report · ข้อตรวจที่ผ่านไม่ครบ · จำนวนคำสั่งและคำสั่งล้มของแต่ละแขน
```

ขั้นที่ 8 · ผลจริง (แขนละ 12 รอบ)

คุณภาพของเว็บไม่ต่างกัน

แขน	คะแนน	คำสั่งต่อรอบ	คำสั่งล้ม	โทเคนขาเข้า	output token	ราคาต่อรอบ
sonnet · ไม่มีสกิล	100%	5.0	0.8	180K	9.4K	$0.191
sonnet · สกิล v0	100%	4.2	0.2	167K	11.4K	$0.230
haiku · ไม่มีสกิล	99.7%	**19.0**	**4.5**	773K	32.1K	$0.033
haiku · สกิล v0	99.7%	**11.0**	**0.3**	548K	31.4K	$0.031

- ทุกแขนได้ 99.7–100% งานนี้โมเดลทำได้เองอยู่แล้ว สกิลเพิ่มคะแนนไม่ได้
- กับ sonnet สกิล v0 ทำให้**แพงขึ้น 21%** โดยคะแนนเท่าเดิม
- กับ haiku สกิล v0 ลดคำสั่งและคำสั่งล้ม: ไม่มีสกิลเปิด `file://` ด้วย Playwright MCP ไม่ได้ 11 ครั้งใน 12 รอบ

ขั้นที่ 8 · ร่องรอยคำสั่งของ 1 รอบ (ข้อมูลจริง)

✻ **Claude** · web-builder · ข้อมูลจริงจาก transcript.jsonl

ภาพเคลื่อนไหวอยู่ใน README (img/gif-web-commands.gif) · โจทย์ t1-coffee-shop รอบ 1 ของแต่ละแขน: ไม่มีสกิล 23 คำสั่ง ล้ม 5 · สกิล v0 10 คำสั่ง ล้ม 1 · สกิล v2 5 คำสั่ง ไม่ล้ม

ขั้นที่ 8 · ก่อนเชื่อตัวเลข

ผลรอบแรก: ไม่มีสกิล 97.9% · สกิล v0 93.2%

#	ตัวตรวจตัดสินผิดอย่างไร	พบได้อย่างไร
G1	ช่อง `type="date"` ถูกตัดสินว่าไม่มีวงโฟกัส	เว็บอ้างอิงไม่ผ่าน
G2	เว็บที่ใช้ `maxlength` ถูกตัดสินว่าเพิ่มข้อความยาวไม่ได้	เปิดเว็บที่พลาด เห็นว่าจอไม่ล้น
G3	บังคับ `aria-describedby` ทั้งที่ `role="alert"` ก็ถูก	อ่านโค้ดของเว็บที่พลาด
G4	บังคับ "ตะกร้า (0)" ทั้งที่ brief ให้แสดง "ตะกร้าว่าง"	กดสั่งซื้อในเว็บที่พลาด
G5	หาช่อง "วันที่" ได้ 2 ชิ้น เว็บที่ใช้งานได้จึงได้ 34%	ข้อความ strict mode violation

หลังแก้ทั้ง 5 จุดและ `grade` ซ้ำทุกแขน: ไม่มีสกิล 100% · สกิล v0 100% · ส่วนต่าง 4.7 จุดเป็นความผิดของตัวตรวจทั้งหมด

ขั้นที่ 9 ปรับสกิล 2 รอบ: v1 ไม่ผ่าน v2 ผ่าน

ลดคำสั่งได้ 39% โดยคะแนนเท่าเดิม

ขั้นที่ 9 · วางพรอมต์

เป้าหมาย: คะแนนไม่ลด คำสั่งต่อรอบลดลง

```
ปรับปรุงสกิล web-builder ด้วยสกิล skill-optimizer ใน container multi-account เป้าหมายคือคะแนนไม่ลดและจำนวนคำสั่งต่อรอบลดลง
- หาสาเหตุจากชุด train ของรุ่น h-v0: เอเจนต์ใช้คำสั่งไปกับอะไร และข้อตรวจใดพลาด แล้วเขียน part2_web-builder/ISSUES.md
- คัดลอก versions/v0 เป็นรุ่นใหม่ แก้ไม่เกิน 3 จุด ให้สคริปต์ verify.cjs ตรวจและเตือนเองก่อนเพิ่มกติกา
- รันรุ่นใหม่ด้วยเงื่อนไขเดียวกับ h-v0 (haiku/low 12 รอบ) แล้วสั่ง gate เทียบกับ h-v0 โดยใช้ --cost-metric tool_calls
- ถ้าไม่ผ่าน ให้จดสาเหตุลง ISSUES.md แล้วทำรุ่นถัดไปอีก 1 รอบ
ตอบ: จุดที่แก้ของแต่ละรุ่น · ตารางเทียบ · ผลประตูพร้อมเหตุผล
```

ขั้นที่ 9.1 · v1

ลดคำสั่งได้ แต่ทำข้อเดิมพัง

จุดที่แก้ใน v1	ส่วนของสกิล
action ใหม่ `reload` `expectBodyText` `expectNoBodyText` `fillLong` · รัน steps ทั้ง 2 ขนาดจอ · ตรวจจอล้นหลัง steps · เตือนเมื่อ steps ขาด	`verify.cjs`
ตาราง "ทุกข้อของ brief ต้องมี step" + 4 กรณีที่มักพลาด · คำนวณเงินเป็นสตางค์	`SKILL.md`
ลบคำสั่งให้ดู screenshot ทุกครั้ง · ห้ามเขียนสคริปต์ Playwright เอง	`SKILL.md`

- คำสั่งต่อรอบ 11.0 → 6.3 และ `g_longtext` 5/6 → 6/6
- แต่ `a_invalid` **ตกจาก 6/6 เหลือ 4/6** และราคาไม่ลด → REJECT
- สาเหตุ: เอเจนต์ทำเฉพาะสิ่งที่ steps ตรวจ และไม่มี step ใดตรวจ `aria-invalid`

- ราคาของ haiku แทบไม่ขยับ ($0.031–0.033) แม้คำสั่งต่างกัน 3 เท่า
- ปัญหาที่เห็นคือคำสั่งมากและล้มบ่อย
- ก่อนรัน v2 จึงเปลี่ยนเป็น `--cost-metric tool_calls`

> การเปลี่ยนนี้ทำหลังเห็นผลของ v1 จึงตัดสิน v2 จากการรันใหม่ 12 รอบ และแสดงผลของตัวชี้วัดเดิมไว้ด้วย

ขั้นที่ 9.3 · ผลจริง: 6 แขน

✻ Claude · ส่วนที่ 2 · ผลจริง 10 พ.ย. 2026 (จัดหน้าจาก results.json)

สกิล web-builder: 6 แขน วัดด้วยโจทย์ชุดเดียวกัน (6 โจทย์ × 2 รอบ = 12 รอบต่อแขน · 32 ข้อตรวจต่อโจทย์)

ผู้ทำ · สกิล	คะแนน	ได้เต็มทุกข้อ	คำสั่งต่อรอบ	คำสั่งล้ม	โทเคนขาเข้า	output token	ราคาต่อรอบ	เวลา (วินาที)	ประตูรับ
sonnet · ไม่มีสกิล	100.0%	12/12	5.0	0.8	180K	9.4K	$0.191	145	
sonnet · สกิล v0	100.0%	12/12	4.2	0.2	167K	11.4K	$0.230	147	
haiku · ไม่มีสกิล	99.7%	11/12	19.0	4.5	773K	32.1K	$0.033	234	
haiku · สกิล v0	99.7%	11/12	11.0	0.3	548K	31.4K	$0.031	219	เส้นฐาน
haiku · สกิล v1	99.5%	10/12	6.3	0.1	370K	34.5K	$0.032	216	REJECT
haiku · สกิล v2	99.7%	11/12	6.7	0.0	410K	39.9K	$0.036	241	ACCEPT

ประตูรับของ v1 ใช้ราคาตามรายการเป็นตัวชี้วัดต้นทุน · ประตูรับของ v2 ใช้จำนวนคำสั่ง (ประกาศก่อนรัน v2) ถ้าใช้ราคาตามรายการ v2 จะไม่ผ่าน เพราะราคาเพิ่ม 16%
คะแนนทุกแขนอยู่ที่ 99.5–100%: งานนี้โมเดลทำได้เองอยู่แล้ว สกิลเปลี่ยน**วิธีทำงาน** ไม่ได้เปลี่ยนคุณภาพของเว็บ

ขั้นที่ 9.3 · v2 = v1 + action expectInvalid

ACCEPT เมื่อวัดด้วยจำนวนคำสั่ง

```
train: 99.6% → 99.6% (+0.0) · ค่าใช้จ่าย $0.03 → $0.04 · คำสั่ง 10.5 → 6.5
val: 100.0% → 100.0% (+0.0) · ค่าใช้จ่าย $0.04 → $0.04 · คำสั่ง 12.0 → 7.0
  ✓ คะแนนเท่าเดิม (อยู่ในช่วงความแกว่ง) และจำนวนคำสั่งลดลงอย่างน้อย 10% [จำนวนคำสั่ง 11 → 6.667 (-39%)]
ผล: ACCEPT ✅ รับ h-v2 แทน h-v0
```

- **ดีขึ้นจริง:** คำสั่ง -39% (เทียบไม่มีสกิล -65%) · ไม่มีคำสั่งล้มใน 12 รอบ · โทเคนขาเข้า -25% · `a_invalid` กลับเป็น 6/6
- **แย่ลง:** output token +27% · ราคาตามรายการ +16% → ถ้าใช้ราคาเป็นตัวชี้วัด v2 ไม่ผ่าน
- **คุณภาพของเว็บเท่าเดิม** 99.7% สกิลเปลี่ยนวิธีทำงาน ไม่ได้ทำให้เว็บดีขึ้น

ขั้นที่ 9.4 · เว็บที่สกิลสร้าง (ตรวจจริงด้วย Playwright)

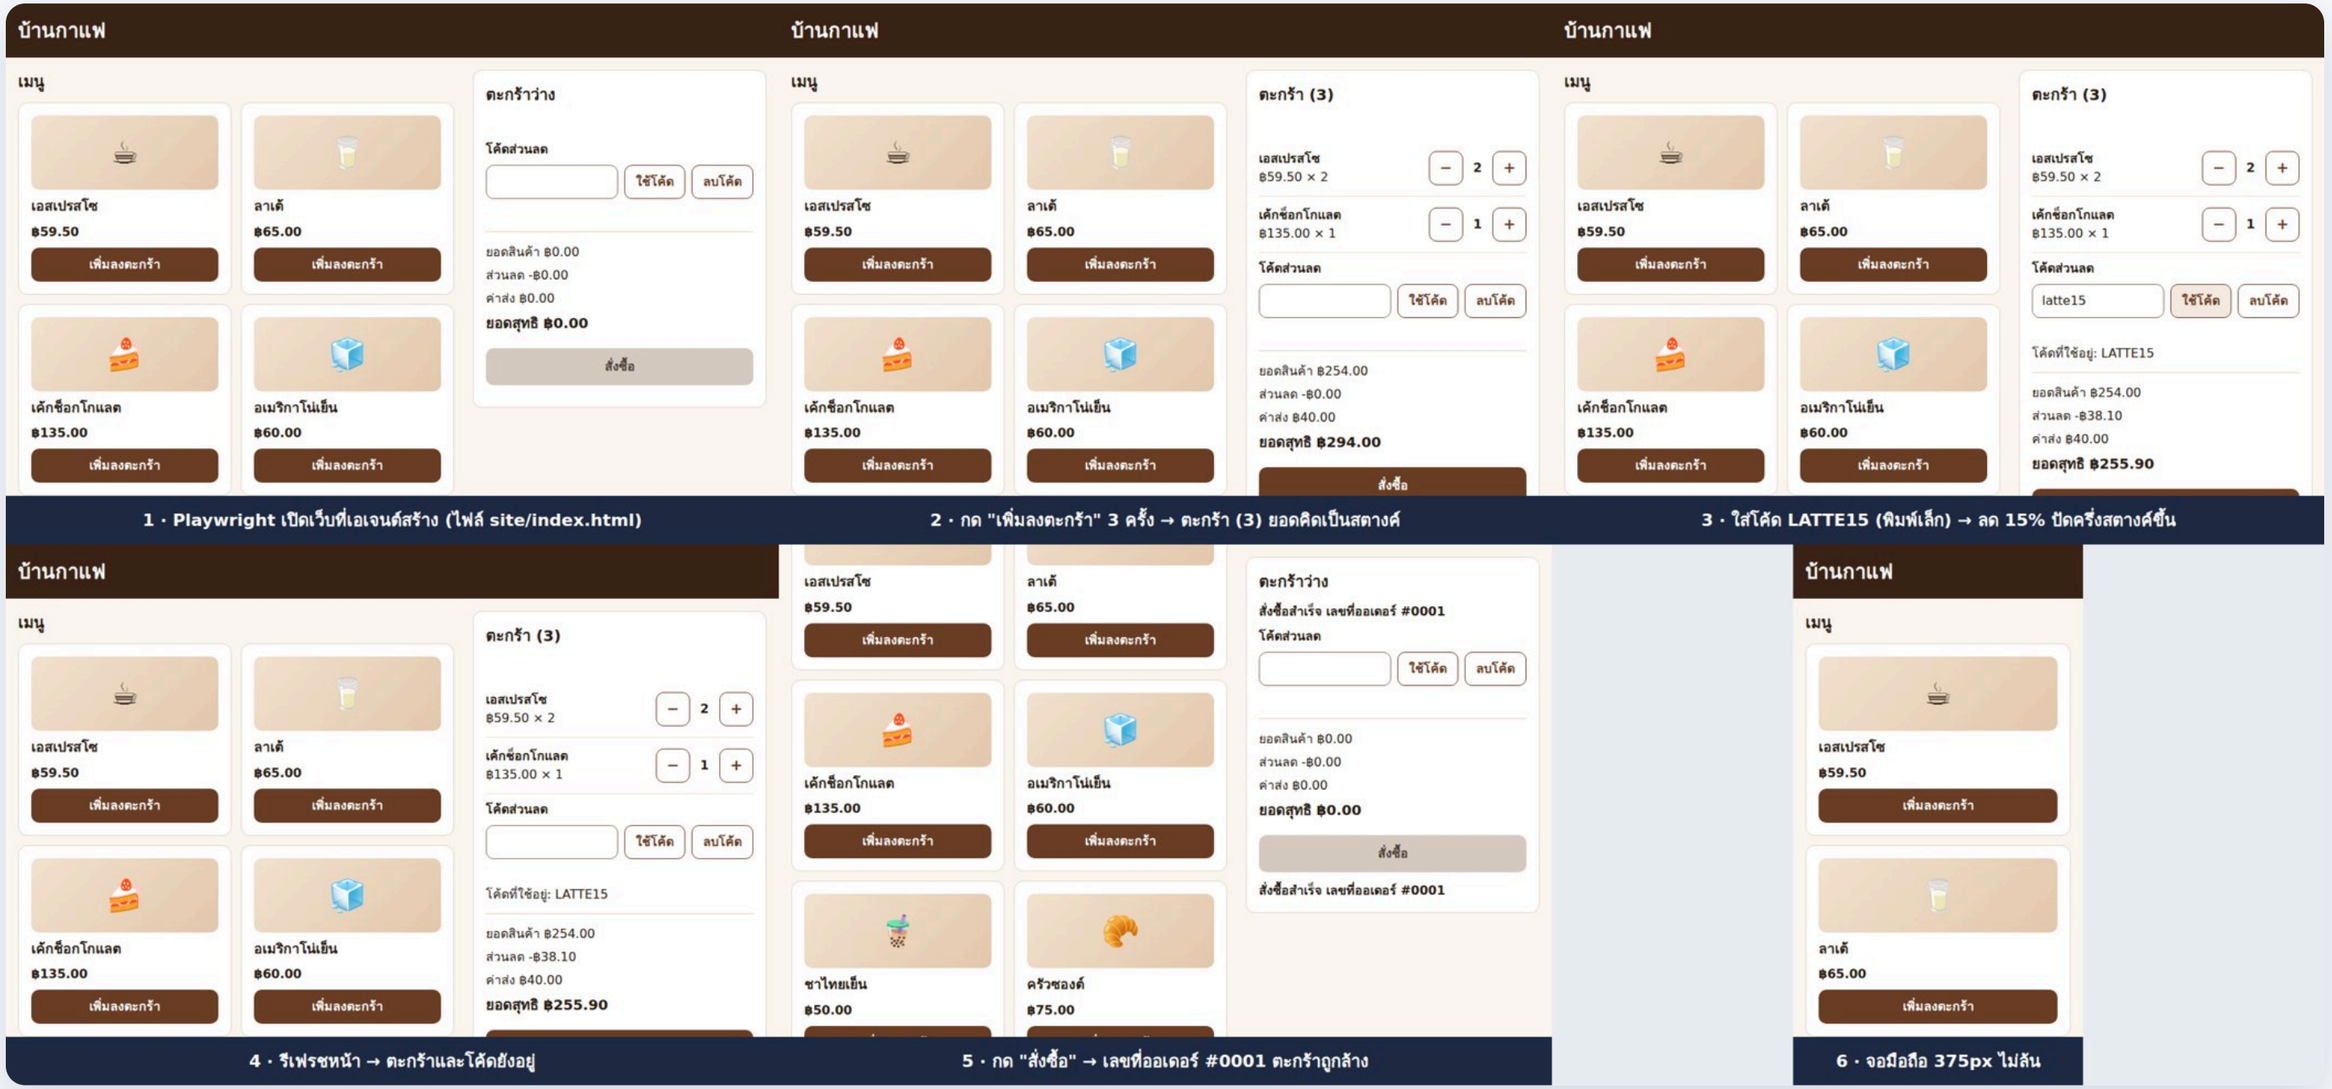

ภาพเคลื่อนไหวอยู่ใน README (img/gif-web-playwright.gif) · เอสเปรสโซ 2 แก้ว + เค้ก 1 ชิ้น = ฿254.00 · ลด 15% = ฿38.10 · ค่าส่ง ฿40.00 · ยอดสุทธิ ฿255.90 · รีเฟรชแล้วยังอยู่ · สั่งซื้อได้ #0001

ส่วนที่ 4 จาก 4

สรุปและข้อควรรู้

อะไรดีขึ้นจริง อะไรไม่ดีขึ้น และ**ต้องระวังอะไร**เมื่อนำไปใช้

สรุป: ปรับปรุงสกิลด้วยหลักฐาน

ส่วนที่ 1 สกิลเดิม dag-planner

- v0 94.7%
- v1 100% ACCEPT
- v2 สั้นลงแต่ไม่ถูกลง REJECT

ส่วนที่ 2 สกิลใหม่ web-builder

- คะแนนเต็มอยู่แล้วตั้งแต่ไม่มีสกิล
- v1 ทำข้อเดิมพัง REJECT
- v2 คำสั่งลด 39% ACCEPT

วัด → หาสาเหตุ → แก้ → วัดซ้ำ → ประตูรับ

6 · สรุป

สองส่วน วงรอบเดียวกัน

	ส่วนที่ 1 · dag-planner	ส่วนที่ 2 · web-builder
เส้นฐาน	v0 94.7%	haiku + v0: 99.7% · 11.0 คำสั่งต่อรอบ
สิ่งที่วัดแล้วพบ	2 จุดอ่อนที่ซ้ำกัน	คุณภาพเต็มอยู่แล้ว ปัญหาอยู่ที่คำสั่งและคำสั่งล้ม
รุ่นที่ผ่านประตู	v1: 100% ทั้ง train และ val	v2: คะแนนเท่าเดิม คำสั่ง -39% ไม่มีคำสั่งล้ม
รุ่นที่ไม่ผ่าน	v2: สั้นลง 14% ค่าใช้จ่ายไม่ลด	v1: ทำข้อ a_invalid พัง
ราคาที่จ่าย	output token +20%	output token +27% · ราคา +16%
ตัวตรวจที่ผิด	1 จุด	5 จุด
รอบที่รัน	48	109

6 · สรุป

ใช้ได้กับสกิลทุกตัว

หลัก	เหตุผลจากผลจริงในบทนี้
วัดก่อนแก้ และวัดแขน "ไม่มีสกิล" ด้วย	งานสร้างเว็บได้ 99.7–100% ตั้งแต่ไม่มีสกิล
ให้สคริปต์เตือนเอง ดีกว่าเพิ่มกติกา	`WARN` แก้ข้อที่พลาดได้ทุกข้อที่ลอง
แก้ทีละน้อยและวัดครบทุกข้อ	v1 ของ web-builder ลดคำสั่งได้ แต่ทำ `a_invalid` พัง
อ่านผลงานก่อนเชื่อคะแนน	ตัวตรวจผิด 6 จุด ครั้งหนึ่งทำให้สกิลดูแย่กว่าไม่มีสกิล 4.7 จุด
เลือกตัวชี้วัดก่อนวัด	v2 ผ่านเมื่อวัดด้วยจำนวนคำสั่ง ไม่ผ่านเมื่อวัดด้วยราคา
สกิลสั้นลงไม่ได้แปลว่าถูกลง	สั้นลง 14% ค่าใช้จ่ายลดไม่ถึง 1%

7 · รันซ้ำใน container multi-account

ยืนยันว่าพรอมต์ทำได้จริงในเครื่องผู้เรียน

ตรวจอะไรใน container	ผลจริง
บัญชี (`team.py check`)	yolo1–3 และ cyolo1–2 พร้อม
Playwright	Chromium 157 เปิดได้ผ่าน `@playwright/mcp/node_modules/playwright`
ส่วนที่ 1 · ชุด val โจทย์ละ 1 รอบ	v0 97.5% → v1 100% · ทั้งสองรุ่น 38 วินาทีต่อรอบ
ส่วนที่ 2 · ชุด val โจทย์ละ 1 รอบ (haiku)	ไม่มีสกิล 21.0 คำสั่ง ล้ม 4.0 → สกิล v2 10.0 คำสั่ง ล้ม 0.0

> ตัวเลขหลักของบทรันบนเครื่องผู้สอนที่เรียก `yoloN` ได้โดยตรง · คะแนนแขนละ 2 รอบใน container ยังบอกอะไรไม่ได้

8 · ข้อควรรู้

ก่อนนำไปใช้

รันโจทย์ใช้โทเคนจริง

บทนี้รัน 157 รอบ เริ่มจาก `--split train --reps 1` ก่อน

จำนวนรอบยังน้อย

แขนละ 12–16 รอบ ส่วนต่าง 0.2 จุดยังอยู่ในความแกว่ง เชื่อได้เฉพาะส่วนต่างที่ใหญ่

ผลขึ้นกับรุ่นของผู้ทำ

สกิล v0 ทำให้ sonnet แพงขึ้น 21% แต่ช่วย haiku ต้องวัดกับรุ่นที่จะใช้จริง

เวลาเทียบข้ามรุ่นได้ยาก

ขึ้นกับงานที่รันพร้อมกันบนเครื่อง ให้ดูจำนวนคำสั่งและโทเคน

ชุด val เล็ก

ส่วนที่ 2 มีโจทย์ val แค่ 2 ข้อ

ยังไม่ได้ปรับ description

พรอมต์ของบทนี้บอกให้อ่านสกิลใน `./skills` เสมอ

9 · คำสั่งที่ใช้บ่อย (ไม่จำเป็นต้องใช้)

สั่งเองใน container

```
O=skills/skill-optimizer/scripts/skillopt.py
python3 $O lint part1_dag-planner/versions/v0
python3 $O run part1_dag-planner/evals --skill part1_dag-planner/versions/v0 --label v0 --reps 2 --accounts yolo2,yolo3
python3 $O null part1_dag-planner/evals --label v0
python3 $O failures part1_dag-planner/evals --label v0 --split train
python3 $O report part1_dag-planner/evals --labels v0,v1
python3 $O gate part1_dag-planner/evals --base v0 --cand v1
# ส่วนที่ 2 (ผู้ทำ haiku/low)
python3 $O run part2_web-builder/evals --skill none --label h-noskill --reps 2 --model haiku --effort low
python3 $O gate part2_web-builder/evals --base h-v0 --cand h-v2 --cost-metric tool_calls
```

- รันที่ `/workspace/07_Skill_Optimization` · `run` ใช้โทเคน คำสั่งอื่นไม่ใช้

สรุป

วัดก่อนแก้ แก้ทีละน้อย แล้วให้ประตูตัดสิน

วัด → หาสาเหตุ → แก้ → วัดซ้ำ → ประตูรับ

dag-planner **94.7%** → **100%** · web-builder **19.0** → **6.7**

คำสั่งต่อรอบ คะแนนเท่าเดิม

รายละเอียดทุกขั้น ลิงก์งานวิจัย และสมุดปัญหาอยู่ใน README.md